

Дорогие участники и участницы!

Спасибо за то, что выбрали этот проект. Мы надеемся, что вы получите удовольствие от его выполнения вместе со всеми.

В этом году каждый проект – сложная и комплексная задача. Не все шаги проекта из представленных могут быть решены в срок. И это нормально! Сам путь, который вы проделываете, может быть даже важнее, чем сам результат. Как часто говорят на “ПАНДАНе”, отсылая к старой японской мудрости: “У студента нет цели, есть только путь.”

А отсутствие подтверждения поставленных гипотез – тоже крутой результат!

Важно помнить, что после мастерской ничего не кончается. Вы можете также продолжать работу над проектом с оставшимися энтузиастами. И мы – кураторы мастерской - будем рады в этом посильно помочь.

Удаленные (и не очень) помощники

Помимо кураторов вам могут помочь удаленные помощники. Они – наши главные партнеры, предоставившие данные и идею проекта. Вы можете с ними пообщаться дистанционно. Они могут ответить на вопросы, касающиеся содержания данных, а возможно, дать совет по поводу решения какого-то этапа (если вы вдруг заблудились).

Для данного проекта (не)удаленным помощником будет [Даша Челнокова](#), наша преподавательница и _____. Можно [написать в Telegram](#) или подойти лично в сроки её пребывания на школе.

Хотим отметить, что наши помощники – не роботы и не БЯМы. У них есть свой график и распорядок основной деятельности. Они не всегда смогут ответить на возникшие вопросы в течение нескольких минут. Учитывайте это! Мы просим относиться ко времени и пространству других людей с уважением 😊

Пожалуйста, не стесняйтесь делиться результатами! Коллеги будут рады получить новый взгляд на свою деятельность! Как только будет результат – смело отправляйте коллегам.

Принципы взаимопомощи

Наша мастерская – отнюдь не про конкуренцию. Мы соревнуемся сами с собой в том, чтобы стать опытнее и лучше. Спрашивать – это нормально. Делиться – это нормально. Не стесняйтесь спрашивать преподавателей. Не смущайтесь просить помощи у других команд. Эти проекты существуют, чтобы люди общались, взаимодействовали и создавали вместе!

Важные сроки

Если вы понимаете, что этот проект – “совсем не моё”, вы можете поменять его до **9 июля включительно**. Просим не делать это сюрпризом для остальной команды, а обсудить свое решение внутри коллектива и **обязательно** известить об этом координатора (обязательно получив его разрешение на перемещение).

Нам важно сохранить баланс каждой команды. Все же, у каждого проекта есть свои лимиты (см. информацию в “Справке” по ссылке).

0.1. В этом проекте Вам предстоит поработать с базой данных о товарах “Самокат”.

0.2. Задания ниже — это не обязательные пункты, а желательные ориентиры. Вы всегда можете придумать что-то свое, если найдете интересные закономерности в данных или захотите исследовать авторскую гипотезу.

0.3 Всячески приветствуется работа с источниками. Для того чтобы работать с данными, нужно знать про их специфику. Сделайте ваши выводы и описание результатов обоснованными научной базой.

Самокат: датасет поисковых запросов и товаров с разметкой релевантности

Немного о данных:

79 774 пары поисковый запрос – товар. Каждая пара размечена по степени релевантности товара запросу. Это реальные пользовательские запросы 2026 года и товары из сервиса доставки еды Самокат.

Колонка	Описание	Пример
query	Поисковый запрос пользователя (9 496 уникальных). Часто содержит опечатки	энергетик без сахара
item_name	Название товара из каталога (35 202 уникальных)	энергетик самокат, без сахара, с соком малины, 0,33 л
item_id	Уникальный идентификатор товара	55e4ae6a298cf3...
final_answer	Оценка релевантности: E (exact – точное соответствие), S (substitute – заменитель), C (complement – дополнение), I (irrelevant – нерелевантный)	e
category4_name	Категория товара, уровень 4 (самый детальный)	энергетические напитки
category3_name	Категория товара, уровень 3	энергетические напитки
category2_name	Категория товара, уровень 2	напитки

category1_name	Категория товара, уровень 1 (самый общий)	безалкогольные напитки
----------------	---	------------------------

Кратко про разметку ESCI: ее придумал Amazon (Shopping Queries Dataset, KDD Cup 2022) для улучшения поиска по товарам, чтобы лучше покрыть возможные соотношения запроса-товара. E (exact) – товар в точности соответствует запросу; S (substitute) – не то же самое, но закрывает потребность («кока-кола» -> «пепси»); C (complement) – сопутствующий товар, который берут вместе («паста» -> «соус»); I (irrelevant) – не подходит. ESC товары для запросов брались из разных позиций поисковой выдачи и отдавались на ручную разметку. В Самокате такие данные используются для обучения векторного поиска и файн-тюна LLM под эту разметку (такая LLM мониторит качество поиска).

1. Исследование запросов

- На какие группы они делятся? Например, на основе эмбедингов, полученных с помощью d0rj/e5-small-en-ru (ее используют в Самокате), ai-forever/sbert_large_nlu_ru, BAAI/bge-m3 или других эмбеддеров. Или по каким-то другим признакам.
- Спроецировать эмбединги запросов в 2D/3D (UMAP/t-SNE/PCA ...). Раскрасить по категориям товаров и т.п.
- Придумать, как вытащить странные запросы пользователей, по которым сложно понять, что хотел найти пользователь: нечитаемый набор букв («тммн», «мдмс», «фппш», «крпзмал»), запросы на других языках («ظماط»), слипшиеся слова («сосискавтесте», «таорожныйсыр»), оборванные запросы («де», «пшен», «кофе зер»), какие есть запросы не про еду («серебряная цепочка», «вышивка крестом», «теннисный мячик») – попробовать обучить классификатор предсказывать тип запроса, или кластеризовать их.
- Поискать интересные лингвистические кейсы в запросах.

2. Обучение моделей предсказывать релевантность

- Обучать модель предсказывать класс релевантности товара запросу (E/S/C/I).
- Можно упростить задачу: relevant (E + S + C) vs irrelevant (I). Или exact (E) vs rest.
- Признаки: доля слов запроса, встречающихся в названии товара, совпадение по подстрокам, TF-IDF сходство, эмбединги (d0rj/e5-small-en-ru, ai-forever/sbert_large_nlu_ru, BAAI/bge-m3 и т.п.) и т.д.
- Модели: логистическая регрессия, SVM, Random Forest, градиентный бустинг и т.п.
- Или перевести в задачу ранжирования: для каждого запроса отранжировать товары по релевантности (товары собрать из тех, что есть в датасете в колонке item_name). Можно сравнить разные эмбеддеры – какой лучше ранжирует?
- Какие признаки оказались наиболее важными?

3. Категории товаров

- Визуализировать иерархию категорий: какие категории самые крупные, как устроено дерево?
- По тексту запроса предсказать категорию товара (на любом из 4 уровней иерархии). Можно попробовать иерархическую классификацию: сначала предсказать category1_name (верхний уровень), потом внутри предсказанной категории уточнить category2_name и т.д. Например, для запроса «пирожное» – сначала предсказать, что это «кондитерские изделия» (а не «напитки» или «бакалея»), потом внутри «кондитерских» определить, что это «торты и пирожные» (а не «конфеты»), и так далее вниз по дереву category1–category4.
- Посмотреть на ошибки модели, изучить важность признаков.

- Попробовать автоматически извлечь из названий товаров атрибуты (бренд, вес, объём, вкус и т.п.) и проанализировать их. Например, какие бренды самые популярные в товарах?

4. Графы заменителей и дополнений

- Из S-меток можно построить граф заменителей: какие товары заменяют друг друга? Какие связи возникают между категориями? Из C-меток тоже – граф, какие товары берут вместе?
- Визуализировать эти графы, найти кластеры.

5. Исправление опечаток

- В запросах много опечаток и сокращений («кроссовки», «пезервати», «косметика», «слбачий корм»). Придумать метод автоматического исправления (расстояние Левенштейна, опечаточник от Яндекса, SymSpell, предобученные модели и т.п.).
- Какая доля запросов содержит опечатки?
- Сравнить: улучшается ли качество предсказания релевантности после исправления опечаток?